Parche de idioma v10: Llama-3.2-3B vs Qwen3-4B

Resultados de las corridas completas **v10** (Llama-3.2-3B-Instruct) y **qwen3_v10** (Qwen3-4B-Instruct-2507). Misma data y misma receta en los dos modelos. 14-10-2026.

1. Qué cambió en la data (v10)

- **Targets nativos.** y = M(q_X): la respuesta del propio modelo a la pregunta escrita en el idioma X, sin instrucción. Antes (v8/v9) era y = M("Answer in X." + q). El parche aprende a imitar lo que el modelo hace cuando le preguntan en X, no lo que hace cuando se le ordena responder en X.
- **Targets por modelo.** Cada modelo se entrena sobre sus propias respuestas (Llama y Qwen generan sus targets por separado).
- **Banco v8:** 700 preguntas, 7 categorías × 100. Split 0.84: 588 train / 112 held-out (16 por categoría).
- **Generación de 250 tokens** (antes 100), para que las explicativas no se corten antes del mecanismo. El entrenamiento usa solo los primeros 8 tokens del target.
- **Traducciones auditadas** a mano contra el inglés: 31 preguntas, 38 arreglos (títulos mal traducidos, sentido cambiado, una fuga del few-shot del traductor, gramática).
- **Revisión a mano de los 2100 targets por modelo.** Se conserva el estilo del modelo; se corrigen errores de contenido, palabras en otro idioma y muletillas de apertura ("¡Claro!"). Respuestas tocadas, de 700 por idioma: Llama fr 463 / es 447 / de 488; Qwen fr 526 / es 552 / de 557. Resultado: 100% acierto, 100% idioma y 100% gate en las tres celdas de ambos modelos.
- **Control nativo** = M(q_X) generado en vivo, sin las correcciones: es la referencia honesta de cuánto acierta el modelo cuando le preguntan en X.
- **Medición.** Idioma con GlotLID; acierto = la respuesta contiene un alias de la respuesta correcta (alias en 6 idiomas).

2. Receta (igual en ambos modelos)

Un único vector v sumado a todos los tokens de la pregunta. Sign-SGD (lr 0.00025, coseno), 10 epochs, batch 28, CE sobre los primeros 8 tokens del target, L2 0.09 (Llama) / 0.0915 (Qwen). Checkpoint usado: mejor CE de train.

3. Entrenamiento

modelo	celda	‖v‖	CE train (e10)	CE held-out (e10)	CE held-out sin parche
Llama	fr / es / de	0.88 / 0.91 / 0.94	0.65 / 0.37 / 0.74	1.02 / 0.92 / 1.24	5.5 (fr)
Qwen	fr / es / de	0.92 / 0.96 / 1.00	1.29 / 1.06 / 1.62	1.42 / 1.27 / 1.77	9.5 (fr)

CE sobre los primeros 5 tokens. En ambos modelos el held-out se estabiliza en 2–4 epochs y lo que sigue baja solo el train. Qwen parte de una CE mucho más alta y baja más (≈ −8 nats vs ≈ −4.5).

4. Held-out (112 preguntas en inglés + parche)

modelo	celda	% idioma: sin / nativo / parche	acierto: sin / nativo / parche	acuerdo parche-nativo
Llama	fr	0 / 99 / 100	97 / 76 / 79	92
Llama	es	0 / 96 / 99	97 / 72 / 82	78
Llama	de	0 / 95 / 99	97 / 78 / 81	80
Qwen	fr	0 / 100 / 97	99 / 84 / 84	88
Qwen	es	1 / 97 / 96	99 / 84 / 84	89
Qwen	de	0 / 98 / 97	99 / 84 / 83	90

sin = sin parche (responde en inglés). nativo = pregunta escrita en el idioma, sin parche. Acuerdo = % de preguntas donde parche y nativo coinciden en acierto/fallo. La caída de acierto respecto a inglés es del modelo al responder en otro idioma, no del parche.

Transferencia: la pregunta llega en otro idioma (% idioma destino con parche)

modelo	celda	es	fr	de	it (no visto)	pt (no visto)
Llama	fr	99	—	99	89	96
Llama	es	—	96	97	91	84
Llama	de	97	100	—	97	89
Qwen	fr	99	—	94	100	97
Qwen	es	—	96	93	83	97
Qwen	de	99	97	—	89	99

Sin parche todas están en 0–2%. Acierto con parche desde otro idioma: Llama 57–70, Qwen 64–80.

5. Prompts abiertos

modelo	open1: 99 prompts en inglés (fr / es / de)	open2: 50 imperativos, entradas en/es/fr/de (rango)
Llama	94 / 96 / 94	92–100
Qwen	89 / 99 / 98	94–100

% de respuestas en el idioma destino con parche. Control nativo: 98–100 en ambos.

6. Geometría

- **Coseno entre los vectores de las tres celdas:** Llama 0.17–0.25, Qwen 0.24–0.27 (dos direcciones al azar: ±0.02). Direcciones distintas, con algo compartido.
- **v no es un token disfrazado:** en Qwen, hasta e + 4v ningún token de las preguntas cambia de vecino más cercano en el vocabulario; recién con 8v cambian 10–67%.

7. Tests de comportamiento (celda fr salvo la resta)

test	Llama	Qwen
Identificación: "¿en qué idioma está?" con parche fr / es / de	76 / 90 / 85	88 / 97 / 99
Instrucción "responde en inglés" + pregunta nativa fr → % fr	72	4
Instrucción "responde en inglés" + parche fr → % fr	77	4
Instrucción "responde en francés" − v_{fr} → % fr	96	100

En los dos modelos el parche se comporta como la pregunta nativa frente a una instrucción en conflicto: Llama prioriza el idioma de la pregunta, Qwen la instrucción.

Resta: pregunta en X menos v_X

pregunta	Llama: % sigue en X → destino	Qwen: % sigue en X → destino
fr − v_{fr}	9 → inglés 84	62 → rumano 24
es − v_{es}	17 → francés 77	52 → rumano 31, portugués 12
de − v_{de}	3 → inglés 96	7 → inglés 63

Restas con vectores al azar de igual norma: 92–100% sigue en X en ambos modelos.

8. Lectura

- **La receta transfiere a Qwen.** Con un solo vector, 96–97% de las respuestas cambian de idioma y el acierto queda igual al de preguntar en el idioma (84 vs 84). Generaliza a idiomas de entrada no vistos (it, pt) y a prompts abiertos.
- **La diferencia está en la resta.** En Llama, restar v_{fr} o v_{es} saca al modelo del idioma. En Qwen, solo en alemán: en fr/es la mayoría sigue en el idioma, y la parte que cambia se va a otra lengua romance (rumano), no al inglés. Hipótesis: en Qwen, v_{fr} y v_{es} codifican el idioma puntual sobre una dirección "romance" que la resta no quita.

Para revisar

- ¿La asimetría de la resta en Qwen alcanza como resultado de comparación entre modelos, o conviene un test dirigido (p. ej. restar el promedio de v_{fr} y v_{es})?
- El acierto se mide por alias; puede haber falsos positivos y negativos en alias cortos. Lo afecta por igual a parche y nativo, pero no se auditó a mano.